

Predykcja składów All-NBA i All-Rookie z wykorzystaniem metod uczenia maszynowego

Daniil Kavalevich

31 maja 2026

1 Wstęp

Nagrody i wyróżnienia indywidualne w NBA, takie jak All-NBA Teams oraz All-Rookie Teams, są ważnym elementem oceny sezonu zawodników. Wybór do tych drużyn zależy od poziomu sportowego gracza, ale nie jest prostym algorytmem opartym wyłącznie na statystykach. Na decyzje głosujących wpływają również reputacja zawodnika, wyniki drużyny, liczba rozegranych meczów, narracja sezonu oraz porównanie z innymi kandydatami na podobnym poziomie.

Celem projektu było zbudowanie systemu predykcyjnego przewidującego skład All-NBA oraz All-Rookie na podstawie danych z sezonu regularnego. Projekt obejmował pobranie i przygotowanie danych, konstrukcję cech, trenowanie modeli, ocenę historyczną oraz analizę błędów. Uzyskane wyniki pokazują, że model dobrze identyfikuje główną grupę kandydatów, natomiast największe trudności pojawiają się przy zawodnikach o zbliżonym poziomie oraz przy dokładnym przypisaniu ich do odpowiednich drużyn.

2 Opis problemu

Celem projektu jest przewidzenie końcowych składów dwóch wyróżnień NBA: All-NBA Teams oraz All-Rookie Teams. W przypadku All-NBA model musi wybrać piętnastu zawodników i przypisać ich do trzech drużyn: First Team, Second Team oraz Third Team. W przypadku All-Rookie wybieranych jest dziesięciu debiutantów, którzy trafiają do First Team albo Second Team.

W projekcie etykiety zostały zakodowane liczbowo. Dla All-NBA wartość 0 oznacza brak wyboru, a wartości 1, 2 i 3 odpowiadają kolejno Third Team, Second Team i First Team. Dla All-Rookie wartość 0 oznacza brak wyboru, wartość 1 oznacza Second Team, a wartość 2 oznacza First Team.

Zadanie można traktować jako połączenie klasyfikacji i rankingu. Model najpierw ocenia pojedynczych zawodników, a następnie sortuje ich w obrębie sezonu i wybiera ograniczoną liczbę najlepszych kandydatów. Jest to konieczne, ponieważ liczba miejsc w drużynach jest stała: 15 zawodników dla All-NBA oraz 10 zawodników dla All-Rookie.

Problem jest trudny, ponieważ rzeczywiste głosowanie nie zależy wyłącznie od statystyk. Na decyzje głosujących wpływają również reputacja zawodnika, sukces drużyny, liczba rozegranych meczów, kontuzje, narracja medialna oraz subiektywne preferencje. Największe trudności pojawiają się przy zawodnikach znajdujących się na granicy wyboru,

gdzie kilku kandydatów może mieć bardzo podobny poziom sportowy. Z tego powodu model może poprawnie wskazać większość głównych kandydatów, ale nadal popełniać błędy przy dokładnym przypisaniu ich do odpowiednich drużyn.

3 Dane

W projekcie wykorzystano dane opisujące sezony regularne zawodników NBA. Dane przygotowano osobno dla dwóch zadań: predykcji składów All-NBA Teams oraz All-Rookie Teams. Oba zbiory korzystają z tej samej bazy statystyk zawodników, ale różnią się zakresem kandydatów oraz etykietami.

Podstawowym źródłem statystyk była biblioteka `nba_api`. Dla każdego sezonu pobierano dane z sezonu regularnego w wariantach **Base**, **Advanced** oraz **Usage**. Pozwoliło to uwzględnić zarówno klasyczne statystyki meczowe, takie jak punkty, zbiórki, asysty, przechwyty, bloki i minuty, jak również informacje o efektywności, użyciu zawodnika oraz kontekście drużynowym.

Drugim źródłem danych były historyczne składy All-NBA Teams oraz All-Rookie Teams, na podstawie których utworzono etykiety uczące. Dodatkowo pobrano statystyki zaawansowane z Basketball-Reference, między innymi PER, WS, WS/48, BPM oraz VORP. Dane te były testowane w części eksperymentów, ale nie weszły do finalnego zestawu cech. Do zbioru dodano również informacje o wyborach do meczu All-Star, ponieważ rzeczywiste głosowanie zależy nie tylko od statystyk bieżącego sezonu, ale także od reputacji i wcześniejszych osiągnięć zawodnika.

Zakres danych obejmuje sezony od 2000 do 2026 roku. Sezony 2000–2025 wykorzystano do trenowania i historycznej walidacji modeli, natomiast sezon 2026 służył jako sezon docelowy do wygenerowania końcowej predykcji. Etykiety nagród są dostępne do sezonu 2025, ponieważ wyniki za sezon 2026 nie były częścią danych uczących.

Końcowym wynikiem etapu przygotowania danych są trzy główne pliki przetworzone: `player_seasons_labeled.csv`, `all_nba_dataset.csv` oraz `all_rookie_dataset.csv`. Pierwszy plik zawiera pełny zbiór zawodników wraz z etykietami, natomiast dwa kolejne są używane bezpośrednio w modelowaniu.

Tabela 1: Podsumowanie najważniejszych plików danych

Plik	Liczba wierszy	Liczba kolumn	Zakres sezonów
<code>player_seasons_raw.csv</code>	13249	159	2000–2026
<code>all_nba_labels.csv</code>	391	4	1999–2025
<code>all_rookie_labels.csv</code>	267	4	2000–2025
<code>bref_advanced_stats.csv</code>	13272	14	2000–2026
<code>all_star_players.csv</code>	1101	4	2000–2026
<code>player_seasons_labeled.csv</code>	13249	229	2000–2026
<code>all_nba_dataset.csv</code>	13249	227	2000–2026
<code>all_rookie_dataset.csv</code>	2140	228	2000–2026

Zbiór `all_nba_dataset.csv` zawiera wszystkich zawodników z analizowanych sezonów. Zbiór `all_rookie_dataset.csv` został ograniczony do zawodników oznaczonych jako kandydaci debiutanczy.

3.1 Dane statyczne dla sezonu 2026

Oprócz danych pobieranych automatycznie wykorzystano niewielki zestaw danych statycznych zapisanych w katalogu `data/static`. Były to ręczne, oficjalne uzupełnienia potrzebne do poprawnego przygotowania sezonu 2026.

Pierwszym elementem był oficjalny skład meczu All-Star 2026. Został dodany jako statyczny snapshot, ponieważ standardowy parser nie obsługiwał poprawnie zmienionego formatu prezentacji składów. Drugim elementem były informacje o kwalifikowalności zawodników do nagród indywidualnych, w szczególności przypadki związane z regułą 65 meczów i oficjalnymi odwołaniami.

Dane statyczne nie stanowią przecieku etykiety docelowej. Model nie otrzymuje informacji o końcowych składach All-NBA ani All-Rookie za sezon 2026. Wykorzystane pliki opisują jedynie fakty znane przed końcowym wyborem drużyn: udział w meczu All-Star oraz formalna kwalifikowalność do nagród.

4 Przygotowanie danych i cechy

Przygotowanie danych polegało na połączeniu kilku źródeł w jeden spójny zbiór sezonów zawodników. Najpierw połączono statystyki `Base`, `Advanced` oraz `Usage` pobrane z `nba_api`. Następnie do danych dodano etykiety All-NBA i All-Rookie, informacje o wcześniejszych wyróżnieniach zawodników oraz dane o występach w meczu All-Star.

Ważnym etapem było ujednolicenie nazw zawodników. Dane pochodziły z różnych źródeł, dlatego te same nazwiska mogły być zapisywane w nieco inny sposób. Zastosowano normalizację nazw, obejmującą usunięcie znaków diakrytycznych, ujednolicenie apostrofów, usunięcie nadmiarowych znaków oraz zmianę liter na małe. Dzięki temu możliwe było stabilne łączenie informacji pochodzących z różnych plików.

Po przeprowadzeniu eksperymentów jako finalny zestaw cech wybrano wariant `previous_team_share_allstar`. Zestaw ten okazał się najbardziej stabilny w głównym modelu HGB oraz w dalszym etapie porządkowania zawodników dla All-NBA. Składa się on z pięciu głównych grup cech: statystyk podstawowych, cech sumarycznych, cech historycznych, cech opisujących rolę zawodnika w drużynie oraz cech All-Star.

4.1 Finalny zestaw cech

Tabela 2: Grupy cech w finalnym zestawie `previous_team_share_allstar`

Grupa cech	Opis
Statystyki podstawowe	Cechy opisujące bieżący sezon zawodnika: wiek, liczba rozegranych meczów, minuty, punkty, zbiórki, asysty, przechwyty, bloki, straty, skuteczność rzutowa oraz wybrane statystyki zaawansowane z <code>nba_api</code> , takie jak <code>OFF_RATING</code> , <code>DEF_RATING</code> , <code>NET_RATING</code> , <code>TS_PCT</code> , <code>USG_PCT</code> i <code>PIE</code> .
Cechy sumaryczne	Agregaty sezonowe obliczone na podstawie średnich i liczby rozegranych meczów, między innymi <code>TOTAL_MIN</code> , <code>TOTAL_PTS</code> , <code>TOTAL_REB</code> , <code>TOTAL_AST</code> , <code>PTS_REB_AST</code> , <code>STOCKS</code> oraz <code>AST_TOV_SIMPLE</code> .
Cechy historyczne	Informacje o poprzednim sezonie zawodnika: czy grał w poprzednim sezonie, czy był wcześniej wybrany do All-NBA, poprzednia etykieta All-NBA oraz wybrane statystyki z poprzedniego sezonu, np. <code>PREV_PTS</code> , <code>PREV_REB</code> , <code>PREV_AST</code> , <code>PREV_GP</code> , <code>PREV_MIN</code> , <code>PREV_W_PCT</code> , <code>PREV_TS_PCT</code> , <code>PREV_USG_PCT</code> i <code>PREV_PIE</code> .
Cechy roli w drużynie	Cechy opisujące znaczenie zawodnika we własnym zespole: ranga w drużynie pod względem punktów, asyst i minut, udział w punktach, asystach i minutach drużyny, informacja czy zawodnik był liderem drużyny oraz pozycja drużyny w lidze pod względem bilansu zwycięstw i net ratingu.
Cechy All-Star	Cechy reputacyjne: czy zawodnik został wybrany do meczu All-Star w bieżącym sezonie, czy był All-Starem w poprzednim sezonie oraz ile razy był wybierany do meczu All-Star przed analizowanym sezonem.

Statystyki podstawowe i sumaryczne opisują aktualną produktywność zawodnika. Są one ważne, ponieważ głosowanie na All-NBA i All-Rookie zależy nie tylko od średnich na mecz, ale również od dostępności zawodnika oraz jego łącznego wkładu w sezonie. Z tego powodu w modelu wykorzystano zarówno statystyki per game, jak i cechy typu `TOTAL_PTS`, `TOTAL_MIN` czy `TOTAL_AST`.

Cechy historyczne i reputacyjne okazały się szczególnie istotne dla zadania All-NBA. Wcześniejsze wybory do All-NBA, wcześniejsze występy w meczu All-Star oraz bieżący status All-Star pomagają modelowi uchwycić status zawodnika w lidze.

Cechy opisujące rolę zawodnika w drużynie zostały dodane, ponieważ same statystyki indywidualne nie zawsze wystarczają do oceny kandydata. Zawodnik zdobywający dużo punktów w słabej drużynie może być oceniany inaczej niż zawodnik o podobnych statystykach będący liderem mocnego zespołu. Dlatego uwzględniono zarówno udział zawodnika w dorobku drużyny, jak i pozycję drużyny w lidze.

4.2 Rezygnacja ze statystyk Basketball-Reference w finalnym modelu

W projekcie testowano również warianty cech zawierające statystyki zaawansowane z Basketball-Reference, między innymi PER, WS, WS/48, BPM oraz VORP. Ostatecznie nie weszły one do finalnego zestawu cech. Powodem była mniejsza stabilność pokrycia danych, szczególnie dla najnowszego sezonu, oraz brak poprawy końcowego wyniku w eksperymentach.

Z tego powodu finalny model wykorzystuje stabilniejszy zestaw `previous_team_share_allstar`, oparty na danych z `nba_api`, cechach historycznych, cechach drużynowych oraz informacjach All-Star.

4.3 Ograniczenia kwalifikowalności

Oprócz cech używanych przez model wprowadzono również twarde ograniczenia kwalifikowalności zawodników. W szczególności dla sezonów objętych regułą 65 meczów zawodnik niekwalifikujący się do nagród nie może zostać umieszczony w predykcji All-NBA. Takie ograniczenie nie jest traktowane jako cecha rankingowa, lecz jako formalny warunek zadania.

W przypadku sezonu 2026 uwzględniono oficjalne informacje o kwalifikowalności zawodników po rozpatrzeniu odwołań. Dzięki temu zawodnik niekwalifikujący się do nagród nie jest wybierany przez finalny skrypt predykcyjny, nawet jeśli jego statystyki sportowe byłyby wysokie.

W praktyce oznacza to, że najpierw odrzucani są zawodnicy z `IS_ALL_NBA_ELIGIBLE` = 0, następnie klasyfikator HGB wybiera najlepszych piętnastu kwalifikujących się graczy, a dopiero potem reorderer przypisuje ich do First, Second i Third Team.

5 Metryka oceny

Do oceny jakości predykcji wykorzystano metrykę punktową zdefiniowaną dla każdej przewidywanej drużyny. Model otrzymuje punkty za wskazanie zawodnika, który rzeczywiście został wybrany do jednej z drużyn All-NBA lub All-Rookie. Liczba punktów zależy od tego, czy zawodnik został przypisany do właściwej drużyny, czy tylko do sąsiedniej drużyny.

Punktacja dla pojedynczego zawodnika jest następująca:

- zawodnik przypisany do prawidłowej drużyny: 10 punktów,
- zawodnik przypisany o jedną drużynę za wysoko lub za nisko: 8 punktów,
- zawodnik przypisany o dwie drużyny za wysoko lub za nisko: 6 punktów,
- zawodnik niewybrany w rzeczywistych wynikach: 0 punktów.

Dodatkowo przyznawany jest bonus za liczbę zawodników poprawnie przypisanych do konkretnej drużyny: 2 trafienia dają +5 punktów, 3 trafienia +10 punktów, 4 trafienia +20 punktów, a 5 trafień +40 punktów. Maksymalny wynik dla jednej drużyny wynosi więc $5 \cdot 10 + 40 = 90$ punktów. Dla All-NBA, gdzie oceniane są trzy drużyny, maksimum wynosi $3 \cdot 90 = 270$, a dla All-Rookie $2 \cdot 90 = 180$. Łączny maksymalny wynik jednej predykcji wynosi 450 punktów.

Predykcje są oceniane dwukrotnie: raz względem oficjalnych wyników NBA oraz drugi raz względem wyborów prowadzącego. Oznacza to, że maksymalna liczba punktów w pełnej ocenie predykcji wynosi $2 \cdot 450 = 900$. W eksperymentach historycznych jako główną wartość porównawczą przyjęto jednak średni wynik dla jednej predykcji, czyli wynik w skali 0–450.

Metryka ma nieliniowy charakter, ponieważ końcowy wynik nie jest tylko sumą niezależnych punktów za pojedynczych zawodników. Duże znaczenie mają również bonusy za dokładnie trafione drużyny. W praktyce oznacza to, że dwa modele mogą wybrać bardzo podobny zestaw zawodników, ale uzyskać inny wynik, jeżeli inaczej przypiszą ich do First, Second i Third Team.

Ten charakter metryki był istotny przy projektowaniu modeli. Samo znalezienie poprawnych kandydatów nie wystarczało, ponieważ duża część punktów zależała od dokładnego przypisania zawodników do właściwych drużyn. Dlatego w projekcie testowano nie tylko modele wybierające kandydatów, ale również osobne etapy porządkowania zawodników.

6 Modele bazowe

Pierwszym etapem pracy było zbudowanie możliwie mocnego modelu bazowego. Taki model miał pełnić rolę punktu odniesienia dla dalszych eksperymentów, dlatego ważne było, aby był oceniany w sposób zgodny z rzeczywistym scenariuszem predykcji. Nie zakładano losowego podziału danych na zbiór treningowy i testowy, ponieważ w tym zadaniu dane mają naturalny porządek czasowy.


Walidację prowadzono metodą kroczącą. Dla każdego sezonu testowego model był trenowany wyłącznie na sezonach wcześniejszych, a następnie sprawdzany na kolejnym sezonie. Po zakończeniu testu dany sezon stawał się częścią danych historycznych dla następnego kroku. Oznacza to, że dla sezonu 2015 model korzystał z danych do sezonu 2014 włącznie, natomiast dla sezonu 2016 mógł już korzystać również z sezonu 2015. W eksperymentach przyjęto zakres testowy od sezonu 2010 do sezonu 2025.

Taki sposób walidacji można zapisać następująco:

$$\text{train}(t) = \{2000, \dots, t - 1\}, \quad \text{test}(t) = \{t\}, \quad t = 2010, \dots, 2025.$$

Dzięki temu każdy wynik sezonowy odpowiada sytuacji, w której model nie ma dostępu do danych z przyszłości.

Przed wyborem ostatecznego modelu bazowego sprawdzono kilka rodzin modeli. Testowane były między innymi klasyfikatory Random Forest, Extra Trees, Gradient Boosting, Histogram Gradient Boosting oraz regresja logistyczna. Dodatkowo w dalszych eksperymentach sprawdzano także podejścia rankingowe i regresyjne oparte na XGBoost, między innymi XGBRanker i XGBRegressor. Równolegle porównywano różne zestawy cech: od prostszych zestawów statystycznych po warianty rozszerzone o cechy historyczne, informacje zespołowe, statystyki zaawansowane oraz sygnały reputacyjne.



Rysunek 1: Porównanie średniego wyniku modeli bazowych w walidacji kroczącej.

Na rysunku 1 przedstawiono porównanie podstawowych modeli bazowych. Najlepszy średni wynik uzyskał klasyfikator Histogram Gradient Boosting, osiągając 256.94 punktu na 450 możliwych. Drugim najlepszym modelem był Random Forest z wynikiem 254.19 punktu. Regresja logistyczna uzyskała 251.38 punktu, natomiast Extra Trees i klasyczny Gradient Boosting osiągnęły odpowiednio 244.75 oraz 244.62 punktu. Na tej podstawie jako główny model bazowy wybrano Histogram Gradient Boosting, dalej oznaczany jako `hgb_classifier`.

Model bazowy traktuje problem jako zadanie klasyfikacji wieloklasowej. Dla All-NBA etykieta 0 oznacza brak wyboru do nagrody, etykiety 1, 2 i 3 odpowiadają odpowiednio trzeciej, drugiej i pierwszej drużynie. Dla All-Rookie etykieta 0 oznacza brak wyboru, a etykiety 1 i 2 odpowiadają drugiej oraz pierwszej drużynie debiutantów.

Po wytrenowaniu model zwraca prawdopodobieństwa przynależności zawodnika do poszczególnych klas. Na ich podstawie obliczany jest oczekiwany wynik zawodnika. Dla All-NBA można go zapisać jako:

$$E(y) = 1 \cdot P(y = 1) + 2 \cdot P(y = 2) + 3 \cdot P(y = 3).$$

Analogicznie, dla All-Rookie wykorzystywane są klasy 1 i 2. Następnie zawodnicy są sortowani według tej wartości. Dla All-NBA wybieranych jest 15 najlepszych zawodników, a dla All-Rookie 10 najlepszych zawodników. W podstawowej wersji przypisanie do drużyn odbywa się przez sortowanie według oczekiwanej etykiety: najwyżej ocenieni zawodnicy trafiają do pierwszej drużyny, kolejni do drugiej, a następni do trzeciej.

W przypadku All-NBA dodatkowo zastosowano filtr formalnej kwalifikowalności. Zawodnicy niespełniający wymogów dotyczących liczby rozegranych meczów lub oznaczeni jako niekwalifikujący się do nagród sezonowych byli usuwani przed końcowym wyborem. Miało to znaczenie szczególnie po wprowadzeniu wymogu 65 rozegranych spotkań, ponieważ zawodnik o bardzo wysokich statystykach mógł być formalnie wykluczony z głosowania.

Klasyfikator HGB został wybrany jako model bazowy z trzech powodów. Po pierwsze, uzyskał najlepszy średni wynik spośród porównywanych modeli. Po drugie, był stabilny w walidacji kroczącej i nie wymagał bardzo skomplikowanej architektury. Po trzecie, dobrze współpracował z dalszymi etapami, ponieważ generował użyteczne prawdopodobieństwa klas oraz ranking kandydatów. Z tego powodu dalsze eksperymenty nie polegały głównie

na zastąpieniu modelu bazowego, lecz na sprawdzeniu, czy można poprawić jego wynik przez dodatkowe mechanizmy po etapie klasyfikacji.

Należy zaznaczyć, że modele bazowe nie były porównywane wyłącznie na jednym, stałym zestawie cech. Dla każdej rodziny modeli sprawdzano różne warianty danych wejściowych, między innymi zestawy prostsze, zestawy z cechami historycznymi oraz warianty rozszerzone o informacje zespołowe i reputacyjne. Na rysunku 1 pokazano najlepszy uzyskany wynik dla każdej rodziny modeli, a nie rezultat pojedynczej, losowo wybranej konfiguracji. Dzięki temu porównanie lepiej odzwierciedla realny potencjał poszczególnych modeli jako kandydatów na model bazowy.


7 Eksperymenty

7.1 Poprawa przypisania zawodników do drużyn All-NBA

Po wyborze modelu bazowego zauważono, że największy problem nie polegał wyłącznie na wskazaniu właściwych zawodników. Klasyfikator HGB dość dobrze wybierał grupę kandydatów do All-NBA, ale część błędów pojawiała się przy przypisaniu zawodników do First, Second albo Third Team. Było to istotne, ponieważ metryka oceny premiuje nie tylko obecność zawodnika w predykcji, ale również poprawne wskazanie konkretnej drużyny.

Z tego powodu przetestowano dodatkowy etap po modelu bazowym. Najpierw HGB wybierał stałą grupę 15 zawodników z najwyższym wynikiem, a następnie drugi model nie zmieniał już składu tej grupy, tylko próbował lepiej rozdzielić zawodników między trzy drużyny All-NBA. Takie podejście oznaczono jako `team_reorderer`.


Główna idea była prosta: jeżeli model bazowy poprawnie znajduje większość kandydatów, to bardziej opłacalne może być poprawienie ich kolejności niż agresywne zmienianie całej listy. Dzięki temu ograniczono ryzyko usunięcia dobrze wybranych zawodników z top-15, a jednocześnie model otrzymał możliwość poprawy końcowego wyniku punktowego.



Rysunek 2: Wynik sezonowy modelu `team_reorderer`.

Na rysunku 2 przedstawiono wyniki modelu `team_reorderer` w kolejnych sezonach testowych. Średni wynik wyniósł 260.50 punktu na 450 możliwych. Model osiągał bardzo

dobrych rezultatów między innymi w sezonach 2018, 2024 i 2025, natomiast słabsze wyniki pojawiały się w sezonach, które były trudniejsze również dla innych modeli.



Rysunek 3: Różnica sezonowa modelu `team_reorderer` względem bazowego klasyfikatora HGB.

Rysunek 3 pokazuje, że dodatkowy etap nie poprawiał wyniku w każdym sezonie, ale średnio dawał dodatni efekt. W wielu latach wynik był taki sam jak dla baseline'u, co oznacza, że oba modele wybierały bardzo podobny zestaw zawodników. Największy zysk pojawiał się wtedy, gdy reorderer poprawiał przypisanie zawodników do odpowiednich drużyn.


Wyniki tego eksperymentu pokazały, że poprawa przypisania zawodników do drużyn All-NBA jest bardziej obiecującym kierunkiem niż ponowny wybór całej puli kandydatów. Model `team_reorderer` stał się więc głównym kandydatem do finalnego rozwiązania i został dalej porównany z innymi wariantami w części wynikowej.

7.2 Model parowy do porządkowania zawodników

Drugim ważnym eksperymentem był model oznaczony jako `team_pairwise`. Jego cel był podobny do poprzedniego podejścia: poprawić przypisanie zawodników do pierwszej, drugiej i trzeciej drużyny All-NBA bez zmieniania całego zestawu top-15. Różnica polegała jednak na sposobie uczenia drugiego etapu.


W modelu `team_reorderer` każdy zawodnik był oceniany osobno pod kątem przynależności do konkretnej drużyny. W podejściu `team_pairwise` model analizował pary zawodników i próbował określić, który z nich powinien znaleźć się wyżej w końcowym rankingu. Następnie na podstawie takich porównań tworzono końcową kolejność zawodników i przypisywano ich do drużyn All-NBA.

Taki sposób modelowania był sensowny, ponieważ problem All-NBA ma charakter rankingowy. W praktyce często nie chodzi o to, czy zawodnik jest dobry sam w sobie, ale czy powinien znaleźć się wyżej niż inni bardzo podobni kandydaci. Dotyczy to szczególnie granicy między pierwszą i drugą drużyną oraz między drugą i trzecią drużyną.



Rysunek 4: Wynik sezonowy modelu `team_pairwise`.

Na rysunku 4 przedstawiono wyniki modelu `team_pairwise` w kolejnych sezonach. Średni wynik wyniósł 260.25 punktu na 450 możliwych, czyli był bardzo zbliżony do wyniku modelu `team_reorderer`. Model osiągał wysokie rezultaty między innymi w sezonach 2018, 2024 i 2025. Podobnie jak w poprzednim eksperymencie, słabsze wyniki występowały w sezonach, w których również inne modele miały większe problemy.



Rysunek 5: Porównanie wyników sezonowych najlepszych modeli.

Rysunek 5 pokazuje, że `team_pairwise` i `team_reorderer` zachowują się bardzo podobnie w większości sezonów. Oba modele zwykle poprawiają lub utrzymują wynik względem bazowego klasyfikatora HGB. Różnice między nimi są niewielkie, ale średnio nieco lepszy okazał się wariant `team_reorderer`.

Model `team_pairwise` potwierdził, że największy potencjał poprawy znajdował się w drugim etapie predykcji All-NBA. Wynik był prawie taki sam jak dla `team_reorderer`, jednak minimalnie niższy, a sam mechanizm był trudniejszy do interpretacji. Z tego powodu model parowy potraktowano jako ważny eksperyment kontrolny, ale nie wybrano go jako rozwiązania finalnego.

7.3 Eksperymenty ze zmianą puli kandydatów

Po uzyskaniu dobrych wyników przez modele porządkujące sprawdzono również, czy można poprawić wynik przez zmianę samego zestawu zawodników wybieranych do All-NBA. W tym celu testowano podejścia, które nie ograniczały się wyłącznie do ponownego przypisania zawodników z top-15, ale próbowały zastąpić część kandydatów zawodnikami znajdującymi się niżej w rankingu modelu bazowego.

Pierwszym takim wariantem był `candidate_pool_stage2`. Model korzystał z szerszej puli kandydatów i próbował zdecydować, czy część zawodników z końca listy top-15 powinna zostać zastąpiona innymi zawodnikami. Celem było poprawienie sytuacji, w których klasyfikator HGB pomijał zawodnika znajdującego się blisko granicy wyboru. W praktyce takie podejście okazało się jednak mniej stabilne niż samo porządkowanie top-15. Model czasami poprawiał pojedyncze przypadki, ale częściej ryzykował usunięcie zawodnika, który został już poprawnie wybrany przez baseline.

Kolejnym eksperymentem był `top40_bubble_reranker`. W tym wariantcie rozważano jeszcze szerszą grupę kandydatów, obejmującą zawodników z okolic miejsc 16–40. Taka konstrukcja dawała modelowi większą swobodę, ale jednocześnie zwiększała liczbę trudnych i bardzo podobnych przypadków. Wyniki pokazały, że rozszerzenie puli kandydatów nie przełożyło się na poprawę końcowego wyniku. Głównym problemem było to, że model musiał rozstrzygać między wieloma zawodnikami o zbliżonych statystykach, co prowadziło do większej liczby błędnych zamian.

Testowano również wariant `top40_vote_support_reranker`, w którym próbowano wykorzystać dodatkową informację związaną z poparciem w głosowaniach z poprzednich sezonów. Ten eksperyment początkowo wyglądał bardzo obiecująco, ale później wykryto błąd metodologiczny: wynik był liczony na innym oknie ewaluacji niż pozostałe modele. Po wyrównaniu zakresu sezonów do przedziału 2010–2025 rezultat nie był już najlepszy, dlatego model nie został wybrany jako rozwiązanie finalne.

Wnioski z tej grupy eksperymentów były istotne dla wyboru końcowej architektury. Modele zmieniające skład top-15 miały teoretycznie większy potencjał, ponieważ mogły naprawiać błędy selekcji kandydatów. W praktyce jednak większa swoboda prowadziła również do większego ryzyka. Najbardziej stabilne okazało się podejście, w którym model bazowy wybiera top-15 zawodników, a drugi etap skupia się wyłącznie na przypisaniu ich do odpowiednich drużyn. Wykresy sezonowe dla tej grupy eksperymentów umieszczono w dodatku A.

7.4 Eksperymenty alternatywne

Oprócz modeli porządkujących oraz wariantów zmieniających pulę kandydatów przetestowano również kilka alternatywnych podejść do samego modelowania problemu. Celem tych eksperymentów było sprawdzenie, czy lepszy wynik można uzyskać nie przez dodatkowy etap po klasyfikatorze HGB, ale przez zastosowanie innego typu modelu lub innego sposobu uczenia.

Pierwszym takim podejściem był `all_nba_vote_regressor`. W tym wariantcie model nie przewidywał bezpośrednio etykiety All-NBA, lecz próbował przewidywać siłę poparcia zawodnika w głosowaniu. Założenie było takie, że wynik głosowania może lepiej opisywać realną kolejność kandydatów niż sama etykieta drużyny. W praktyce regresja na wynik głosowania nie poprawiła jednak wyniku końcowego. Prawdopodobnie wynika to z faktu, że głosy zawierają dodatkowy szum, zależą od kontekstu medialnego i reputacji zawodnika, a nie zawsze bezpośrednio przekładają się na metrykę używaną w projekcie.

Drugim podejściem był `rank_ensemble`, czyli połączenie rankingów generowanych przez kilka modeli. Celem było zmniejszenie wpływu błędów pojedynczego modelu poprzez uśrednienie ich predykcji. Taki pomysł jest często skuteczny, gdy modele popełniają różne błędy. W tym projekcie wyniki ensemble nie były jednak lepsze od finalnego rozwiązania. Można przypuszczać, że testowane modele korzystały z podobnych informacji i dlatego popełniały podobne błędy, przez co ich połączenie nie dawało dużej dodatkowej wartości.

Przetestowano także modele XGBoost: `xgb_ranker` oraz `xgb_regressor`. Model rankingowy miał bezpośrednio uczyć się kolejności zawodników w obrębie sezonu, natomiast model regresyjny przewidywał wartość liczbową odpowiadającą sile kandydata. Oba podejścia były konkurencyjne i dawały sensowne wyniki, ale nie przewyższyły klasyfikatora HGB ani modeli z dodatkowym etapem porządkowania All-NBA. Oznacza to, że sama zmiana rodziny modelu nie rozwiązywała głównego problemu zadania.

Wyniki tych eksperymentów pokazują, że alternatywne podejścia były wartościowym punktem porównania, ale nie dawały jednoznacznej przewagi nad modelem bazowym i wariantami porządkującymi. Dlatego w dalszej części raportu zestawiono je z modelem finalnym oraz oceniono ich wpływ na wynik końcowy.

8 Wyniki

W tej części zestawiono końcowe wyniki eksperymentów oraz uzasadniono wybór modelu finalnego. Jako główną miarę porównawczą przyjęto średni wynik uzyskany w walidacji kroczącej dla sezonów 2010–2025. Wynik liczono łącznie dla All-NBA oraz All-Rookie, dlatego maksymalna liczba punktów w jednym sezonie wynosiła 450.

8.1 Porównanie końcowych wyników


Tabela 3 przedstawia najważniejsze wyniki uzyskane przez testowane warianty modeli. Wartości pokazują średni wynik w historycznym backteście dla sezonów 2010–2025.

Tabela 3: Porównanie średnich wyników najważniejszych eksperymentów.

Model	All-NBA	All-Rookie	Łącznie	Zmiana vs HGB
<code>team_reorderer</code>	143,88	116,62	260,50	+3,56
<code>team_pairwise</code>	143,62	116,63	260,25	+3,31
<code>hgb_classifier</code>	140,31	116,63	256,94	0,00
<code>top40_bubble_reranker</code>	139,38	116,62	256,00	-0,94
<code>top40_vote_support_reranker</code>	136,56	116,63	253,19	-3,75
<code>xgb_ranker</code>	136,37	116,63	253,00	-3,94
<code>rank_ensemble</code>	136,25	116,63	252,88	-4,06
<code>xgb_regressor</code>	134,43	116,63	251,06	-5,88
<code>candidate_pool_stage2</code>	133,13	116,62	249,75	-7,19
<code>all_nba_vote_regressor</code>	129,56	116,63	246,19	-10,75


Najlepszy średni wynik uzyskał model `team_reorderer`, osiągając 260.50 punktu na 450 możliwych. Drugim najlepszym modelem był `team_pairwise`, którego wynik wyniósł 260.25 punktu. Bazowy model `hgb_classifier` uzyskał 256.94 punktu.

Różnica między najlepszym modelem a baseline’em nie jest bardzo duża, ale jest zgodna z charakterem problemu. HGB już dobrze wybierał główną grupę kandydatów, dlatego największy potencjał poprawy dotyczył nie samego znalezienia zawodników, lecz ich dokładnego przypisania do odpowiednich drużyn All-NBA.



Rysunek 6: Zmiana średniego wyniku względem bazowego klasyfikatora HGB.

Rysunek 6 pokazuje, że wyraźną poprawę względem baseline’u dały tylko dwa podejścia: `team_reorderer` oraz `team_pairwise`. Pozostałe eksperymenty były wartościowe jako porównanie, ale nie poprawiły końcowego wyniku. W szczególności modele zmieniające skład top-15 oraz alternatywne modele rankingowe nie okazały się lepsze od prostszego podejścia opartego na HGB i dodatkowym porządkowaniu.



Rysunek 7: Składowe średniego wyniku: All-NBA oraz All-Rookie.

Rysunek 7 pokazuje, że różnice między modelami wynikały głównie z części All-NBA. Wynik All-Rookie był stosunkowo stabilny, a najlepsze warianty nie poprawiały go wzglę-

dem baseline’u. Oznacza to, że dodatkowe etapy były najbardziej użyteczne dla All-NBA, gdzie występują trzy drużyny, więcej kandydatów oraz większe znaczenie dokładnego przypisania zawodników do odpowiedniego poziomu wyróżnienia.

8.2 Model finalny

Na podstawie wyników eksperymentów jako finalne rozwiązanie wybrano architekturę mieszaną. Dla All-NBA zastosowano model dwuetapowy: klasyfikator HGB wybierał piętnastu kandydatów, a następnie `team_reorderer` poprawiał przypisanie tych zawodników do First, Second i Third Team. Dla All-Rookie pozostawiono sam klasyfikator HGB, ponieważ dodatkowe etapy nie dawały stabilnej poprawy wyniku.

Finalny model można więc zapisać następująco:

All-NBA: HGB classifier + fixed top-15 reorderer

All-Rookie: HGB classifier

Taki wybór był kompromisem między jakością wyniku, stabilnością i prostotą rozwiązania. Model `team_reorderer` osiągnął najwyższy średni wynik, a jednocześnie nie zmieniał agresywnie listy kandydatów wybranych przez HGB. Dzięki temu ograniczono ryzyko usunięcia poprawnie wybranych zawodników z top-15. W przypadku All-Rookie prostszy klasyfikator był wystarczający, ponieważ zadanie obejmuje mniejszą liczbę zawodników i dwie drużyny zamiast trzech.

8.3 Predykcja dla sezonu 2026

Po wyborze modelu finalnego wytrenowano go na wszystkich dostępnych sezonach historycznych do 2025 roku włącznie, a następnie wygenerowano predykcję dla sezonu 2026. W predykcji uwzględniono również formalne ograniczenia kwalifikowalności zawodników do nagród posezonowych.

Końcowa predykcja All-NBA dla sezonu 2026 była następująca:

Tabela 4: Predykcja All-NBA Teams dla sezonu 2026.

Drużyna	Zawodnicy
First Team	Shai Gilgeous-Alexander, Luka Dončić, Nikola Jokić, Kawhi Leonard, Victor Wembanyama
Second Team	Jaylen Brown, Cade Cunningham, Donovan Mitchell, Kevin Durant, Jamal Murray
Third Team	Jalen Brunson, Tyrese Maxey, Alperen Sengun, Jalen Johnson, Karl-Anthony Towns

Końcowa predykcja All-Rookie dla sezonu 2026 była następująca:

Tabela 5: Predykcja All-Rookie Teams dla sezonu 2026.

Drużyna	Zawodnicy
First Team	Cooper Flagg, Kon Knueppel, VJ Edgecombe, Cedric Coward, Maxime Raynaud
Second Team	Ace Bailey, Dylan Harper, Jeremiah Fears, Derik Queen, Collin Murray-Boyles

Warto podkreślić, że predykcja dla sezonu 2026 została wygenerowana przez ten sam pipeline, który był używany w eksperymentach historycznych. Dane zostały przygotowane automatycznie, modele zostały wytrenowane na sezonach historycznych, a końcowy plik predykcji został zapisany w formacie JSON.

8.4 Ocena predykcji względem rzeczywistych wyników

Po ogłoszeniu rzeczywistych składów All-NBA oraz All-Rookie dla sezonu 2026 możliwe było dodatkowe sprawdzenie jakości finalnej predykcji. W tej ocenie wykorzystano tę samą metrykę punktową, która była stosowana w historycznym backteście. Dzięki temu wynik dla sezonu 2026 można bezpośrednio porównać ze średnim wynikiem modelu na poprzednich sezonach.

Dla oficjalnych wyników NBA finalna predykcja uzyskała 157 punktów na 270 możliwych w części All-NBA oraz 136 punktów na 180 możliwych w części All-Rookie. Łącznie daje to:

$$157 + 136 = 293$$

punktów na 450 możliwych, czyli:

$$\frac{293}{450} \cdot 100\% = 65.11\%.$$

Tabela 6: Ocena finalnej predykcji dla sezonu 2026 względem oficjalnych wyników NBA.

Część predykcji	Wynik	Maksimum	Procent
All-NBA	157	270	58.15%
All-Rookie	136	180	75.56%
Łącznie	293	450	65.11%

Wynik ten jest wyraźnie wyższy od średniego wyniku uzyskiwanego przez finalną konfigurację w walidacji historycznej. W backteście dla sezonów 2010–2025 model `team_reorderer` osiągał średnio 260.50 punktu na 450 możliwych, czyli 57.89%. Oznacza to, że predykcja dla sezonu 2026 była lepsza od średniego wyniku historycznego o 32.50 punktu.

Tabela 7: Porównanie wyniku sezonu 2026 ze średnim wynikiem historycznym.

Ocena	Wynik / 450	Procent
Średni wynik historyczny modelu finalnego	260.50	57.89%
Wynik predykcji dla sezonu 2026	293.00	65.11%
Różnica	+32.50	+7.22 p.p.

Najlepszy rezultat model uzyskał w części All-Rookie, gdzie predykcja była bardzo bliska oficjalnym wynikom. W pierwszej drużynie poprawnie wskazano czterech zawodników, a piąty zawodnik został przesunięty tylko o jedną drużynę. W drugiej drużynie również czterech zawodników zostało przypisanych dokładnie, a jeden zawodnik znajdował się w

predykcji, ale w innej drużynie. Dzięki temu część All-Rookie uzyskała 136 punktów na 180 możliwych.

W przypadku All-NBA model również poprawnie wskazał większość głównych kandydatów, ale część błędów dotyczyła dokładnego przypisania do drużyn oraz zawodników z końca listy. Przykładowo Cade Cunningham został w rzeczywistych wynikach wybrany do First Team, natomiast model umieścił go w Second Team. Z kolei Kawhi Leonard i Jalen Brunson zostali przez model wybrani do innych drużyn niż w oficjalnych wynikach. Mimo tych przesunięć model zdobywał za nich część punktów, ponieważ byli to zawodnicy faktycznie wybrani do All-NBA.

Najważniejszy wniosek z tej oceny jest taki, że finalny model nie tylko uzyskał najlepszy średni wynik w backteście, ale również dobrze poradził sobie na sezonie docelowym 2026. Wynik 293 punktów na 450 możliwych był wyższy niż średni wynik historyczny, co potwierdza, że model finalny zachował skuteczność również poza zbiorem sezonów używanych do wyboru konfiguracji.

9 Analiza błędów

Analiza błędów pokazała, że model najczęściej radził sobie dobrze z oczywistymi kandydatami do wyróżnień. Najlepsi zawodnicy sezonu, szczególnie gracze z wysoką produktywnością i silną pozycją w lidze, zwykle byli poprawnie rozpoznawani. Największe problemy pojawiały się natomiast przy zawodnikach znajdujących się na granicy wyboru oraz przy dokładnym przypisaniu ich do odpowiednich drużyn.

9.1 Błędy na granicy wyboru

Pierwszym typowym źródłem błędów byli zawodnicy znajdujący się blisko granicy top-15 w przypadku All-NBA oraz top-10 w przypadku All-Rookie. W takich sytuacjach różnice między kandydatami są często bardzo małe. Kilku zawodników może mieć podobne statystyki, podobny wpływ na grę zespołu i zbliżony status w lidze.

W rzeczywistym głosowaniu o wyborze mogą wtedy decydować czynniki trudne do pełnego zakodowania w danych, takie jak narracja sezonu, reputacja zawodnika, popularność medialna albo sposób postrzegania jego roli w drużynie. Dlatego model może poprawnie ocenić ogólną siłę zawodnika, ale nadal wybrać innego kandydata z bardzo podobnego poziomu.

9.2 Błędy przypisania do drużyn

Drugim ważnym źródłem błędów było przypisanie zawodników do właściwej drużyny. Model mógł poprawnie wybrać zawodnika do All-NBA, ale umieścić go na innym poziomie wyróżnienia, na przykład w Second Team zamiast First Team. Metryka częściowo toleruje takie błędy, ale dokładne przypisanie ma duże znaczenie ze względu na bonusy za poprawnie trafione piątki.

Ten problem był główną motywacją do wprowadzenia drugiego etapu w modelu All-NBA. Klasyfikator HGB dobrze identyfikował wielu kandydatów, ale nie zawsze ustawiał ich w kolejności zgodnej z rzeczywistymi wynikami. Dlatego modele `team_reorderer` oraz `team_pairwise` skupiały się właśnie na poprawie tego etapu.

9.3 Różnice między All-NBA i All-Rookie

Błędy w zadaniach All-NBA i All-Rookie miały nieco inny charakter. W przypadku All-NBA model musiał wybrać piętnastu zawodników z całej ligi i rozdzielić ich na trzy drużyny. Jest to trudne, ponieważ kandydaci są bardzo mocni, a różnice między zawodnikami z drugiej i trzeciej drużyny są często niewielkie.

W przypadku All-Rookie pula kandydatów jest mniejsza, ale dostępnych jest mniej informacji historycznych. Debiutanci nie mają jeszcze długiej historii występów w NBA, dlatego model w mniejszym stopniu może korzystać z cech reputacyjnych i wyników z poprzednich sezonów. Mimo to dodatkowe etapy porządkowania nie poprawiały stabilnie wyniku All-Rookie, dlatego w modelu finalnym pozostawiono prostszy klasyfikator HGB.

9.4 Wpływ metryki i ograniczeń danych

Metryka dodatkowo wzmacnia znaczenie błędów przypisania do drużyn. Dwa modele mogą wskazać podobną liczbę poprawnych zawodników, ale uzyskać różny wynik, jeżeli inaczej rozdzielią ich między First, Second i Third Team. Wynika to z punktów częściowych oraz bonusów za dokładnie trafione piątki.

Część błędów wynika również z ograniczeń danych. Model korzysta głównie ze statystyk sezonowych, informacji historycznych i wybranych cech reputacyjnych. Nie wszystkie czynniki wpływające na głosowanie są jednak łatwe do zapisania w tabeli. Trudno w pełni zakodować narrację medialną, oczekiwania wobec zawodnika, wpływ kontuzji na postrzeganie sezonu albo subiektywne preferencje głosujących.

Oznacza to, że target w tym zadaniu jest naturalnie zaszumiony. Nie istnieje jedna prosta reguła, która na podstawie statystyk jednoznacznie wyznacza składy All-NBA i All-Rookie. Model może więc dobrze przybliżać proces wyboru, ale nie powinien być traktowany jako system zdolny do idealnego odtworzenia głosowania w każdym sezonie.

10 Wnioski

Celem projektu było zbudowanie modelu przewidującego składy All-NBA oraz All-Rookie na podstawie danych z sezonu regularnego. Zadanie miało charakter rankingowy, ponieważ model musiał nie tylko wskazać zawodników otrzymujących wyróżnienia, ale również przypisać ich do odpowiednich drużyn.

Najlepszym modelem bazowym okazał się klasyfikator Histogram Gradient Boosting. W porównaniu z innymi modelami bazowymi, takimi jak Random Forest, Extra Trees, Gradient Boosting czy regresja logistyczna, osiągnął on najwyższy średni wynik w walidacji kroczącej. Model ten dobrze identyfikował główną grupę kandydatów, dlatego został użyty jako pierwszy etap finalnego rozwiązania.


Najważniejszy wniosek z eksperymentów jest taki, że największą poprawę dawało nie zastąpienie modelu bazowego inną rodziną modeli, lecz dodanie drugiego etapu dla All-NBA. Model `team_reorderer` poprawiał przypisanie zawodników wybranych przez HGB do First, Second i Third Team. Takie podejście osiągnęło najlepszy średni wynik w back-teście: 260.50 punktu na 450 możliwych.

Finalny model dobrze poradził sobie również na sezonie docelowym 2026. Po porównaniu z oficjalnymi wynikami NBA predykcja zdobyła 293 punkty na 450 możliwych, czyli 65.11%. Jest to wynik wyższy od średniego wyniku historycznego finalnej konfiguracji.


Ograniczeniem rozwiązania pozostaje naturalnie zaszumiony charakter problemu. Wybory All-NBA i All-Rookie zależą nie tylko od statystyk, ale również od reputacji zawodników, narracji sezonu, kontuzji, wyników drużyny i subiektywnej oceny głosujących. W przyszłości projekt można rozwijać przez dodanie lepszych cech opisujących kontekst sezonu, danych o kontuzjach, informacji medialnych lub bardziej szczegółowych danych.

A Dodatkowe wykresy eksperymentów


W dodatku umieszczono wykresy sezonowe dla eksperymentów, które zostały przetestowane, ale nie zostały szczegółowo omówione w głównej części raportu. Modele te stanowiły ważny punkt porównania, jednak nie zostały wybrane jako rozwiązanie finalne, ponieważ nie poprawiły średniego wyniku względem najlepszych wariantów opartych na porządkowaniu zawodników All-NBA.




Rysunek 8: Wynik sezonowy eksperymentu `candidate_pool_stage2`.




Rysunek 9: Wynik sezonowy eksperymentu `top40_bubble_reranker`.




Rysunek 10: Wynik sezonowy eksperymentu top40_vote_support_reranker.




Rysunek 11: Wynik sezonowy eksperymentu all_nba_vote_regressor.



Rysunek 12: Wynik sezonowy eksperymentu `rank_ensemble`.



Rysunek 13: Wynik sezonowy eksperymentu `xgb_ranker`.



Rysunek 14: Wynik sezonowy eksperymentu `xgb_regressor`.